Parecer sobre o relatório técnico v1

O que um professor de estatística criticaria, e por quê

estranhaeleicao.org · 02/11/2026 · sobre Padrões numéricos alegados como fraude no 2º turno presidencial de 2026, versão 1

Para que serve este documento. Antes de virar artigo, o relatório v1 foi lido como um parecerista de revista leria. As dezesseis críticas abaixo estão em ordem de gravidade. Para cada uma: o que o v1 diz, por que isso é um problema (com a intuição estatística, que é o que interessa para quem está aprendendo) e o que a versão 2 faz. Ele é também o roteiro da v2.

Como ler a gravidade. *Grave*: sozinha, faria a revista rejeitar o artigo. *Séria*: pede revisão maior, com análises novas. *Forma*: não muda os resultados, mas muda a confiança de quem lê.

O resumo do parecer. O trabalho é honesto e acima da média em transparência: pré-registro, multiverso, erros documentados, limites declarados. Mas a inferência se apoia numa única eleição de referência e em modelos nulos que o próprio texto mostra estarem mal calibrados, e as conclusões de "compatibilidade" são mais fracas do que a redação sugere. A contribuição mais sólida hoje é descritiva: a conferência das seções e o mapa de quais testes têm poder contra quais formatos de fraude.

Gravidade	Críticas
grave	1 a 5
séria	6 a 10
forma	11 a 16

1. Comparar um ponto com um ponto	grave
O que o v1 diz	A regra de decisão diz que 2026 é atípico se ficar além de 2022. No C1, a decisão saiu de comparar O/E = 2,67 (2026) com O/E = 3,05 (2022), sem intervalo para nenhum dos dois.
Por que é um problema	Para dizer que algo é raro, é preciso saber como o normal varia. Uma única eleição de referência não tem variância: é um ponto. Imagine medir a altura de um aluno e compará-la com a de um único colega. Se ele for mais baixo, você não pode concluir que tem altura típica; só que não é mais alto que aquele colega. E se o próprio colega for atípico, a comparação inteira desloca. O v1 também trata 2022 como se fosse medido sem erro, quando ele foi estimado pelo mesmo modelo, com a mesma incerteza.
O que a v2 faz	Uma classe de referência com várias eleições (2º turno presidencial de 2010, 2014, 2018 e 2022 e os segundos turnos de governador desses anos). Cada estatístico passa a ter uma distribuição de referência, e 2026 é reportado pelo percentil em que cai. A incerteza de cada eleição entra no cálculo.

2. Modelos nulos mal calibrados	grave
O que o v1 diz	O modelo do C1 erra por um fator de 3 nos dois anos (O/E de 2,7 e 3,1). O modelo limpo de Klimek atribui "fraude incremental" a 60% das seções de 2022 e a 71% do governador. O v1 diz que a comparação com 2022 resolve isso.
Por que é um problema	Um p-valor só tem o significado que promete se o modelo nulo descrever bem os dados quando não há nada. Se o modelo já erra muito sem fraude, um p-valor pequeno mede o erro do modelo, não a fraude. Comparar com 2022 só cancela o erro se ele for o mesmo nos dois anos (como uma balança desregulada: comparar dois pesos na mesma balança funciona só se o desvio for constante). Essa premissa não foi testada.
O que a v2 faz	Diagnósticos de calibração antes de qualquer teste: probabilidade prevista contra frequência observada por faixa (gráfico de calibração), checagem preditiva das contagens baixas e do histograma 2D. A premissa de erro constante passa a ser testada na classe de referência: se o erro do modelo varia muito entre eleições limpas, isso entra na distribuição de referência.

3. "Compatível" não é "igual"	grave
O que o v1 diz	Cinco testes saíram "compatível com 2022". Só o C6 tinha faixa de equivalência.
Por que é um problema	Não rejeitar uma hipótese não é aceitá-la. Ausência de evidência não é evidência de ausência. Um teste com pouco poder "não acha nada" quase sempre, e isso não diz que não há nada. Para afirmar que duas coisas são parecidas é preciso fixar antes o quanto é "parecido" (uma margem) e mostrar que o intervalo inteiro cabe nela. É o teste de equivalência (TOST, dois testes unilaterais).
O que a v2 faz	Margem de equivalência registrada para cada teste antes de rodar, e a leitura em três categorias: equivalente (intervalo dentro da margem), atípico (fora, na direção alegada) e inconclusivo (atravessa a margem). "Compatível" sai do vocabulário.

4. A análise de poder é circular	grave
O que o v1 diz	O P1 planta fraude S em cima do dado observado e conclui que "se S tivesse acontecido, teríamos visto".
Por que é um problema	Se S tivesse acontecido, o dado observado já seria "limpo + S". Plantar S em cima dele simula "limpo + 2S". O argumento só vale supondo que o observado é limpo, que é justamente o que se quer testar. Além disso, a fraude foi sorteada ao acaso, e fraude real seria estratégica (em redutos, em seções de comparecimento alto, onde há pouca fiscalização). E a conclusão "1% é detectado, logo 1,8% também" supõe que a detecção cresce sempre com o tamanho, o que não foi verificado.
O que a v2 faz	Três mudanças: (a) plantar fraude também nas eleições da classe de referência, que servem de base "limpa por hipótese" independente de 2026, e dizer a premissa por escrito; (b) acrescentar desenhos estratégicos: concentrada nos municípios mais favoráveis ao vencedor, em seções de comparecimento alto e em seções sem fiscal (proxy: seções pequenas e rurais); (c) uma grade mais fina de tamanhos, incluindo 1,8% (o que vira a eleição), com a curva de poder em vez de pontos soltos. Intervalo de Clopper-Pearson em toda taxa reportada.

5. Inferência onde não há amostra	grave
O que o v1 diz	A reconciliação diz que, com 0 divergências em 499.205 seções, o limite superior de 95% é de 6 seções divergentes por milhão (Clopper-Pearson).
Por que é um problema	Intervalos de confiança medem a incerteza de usar uma amostra no lugar da população. Aqui foram conferidas todas as seções: é um censo. A proporção de divergentes não é estimada, é conhecida, e é zero. O limite de "6 por milhão" responde a uma pergunta que não existe e sugere uma incerteza que não há. A incerteza que existe é de outra natureza: os três arquivos saem da mesma fonte.
O que a v2 faz	O resultado passa a ser determinístico: "0 de 499.205 seções". O limite que importa é dito por escrito (consistência interna, não correspondência com o voto digitado). O mesmo ajuste vale para o site.

6. Graus de liberdade do pesquisador	séria
O que o v1 diz	Cada teste recebeu um "esclarecimento" escrito antes de rodar, mas por quem já conhecia os dados. O carimbo de data é uma tag no git do próprio autor.
Por que é um problema	O valor de um pré-registro está em fixar as escolhas antes de saber como elas afetam o resultado. Quando sobra muita coisa em aberto, o analista volta a escolher (mesmo de boa-fé), e o pré-registro protege menos do que parece. E um carimbo controlado pelo próprio autor pode, em princípio, ser refeito.
O que a v2 faz	Adendo v2 do pré-registro com as decisões que antes ficaram para depois já fixadas; registro no OSF (carimbo independente); e uma lista das escolhas feitas depois de ver dados, com o efeito de cada uma.

7. Dependência entre observações	séria
O que o v1 diz	O C1 simula as seções como independentes. O C4 permuta a hora dentro do município. O BH supõe uma estrutura de dependência entre os seis p-valores.
Por que é um problema	Seções do mesmo local de votação e da mesma zona se parecem (mesmo bairro, mesmo eleitorado, mesma logística). Tratar observações correlacionadas como independentes encolhe os erros-padrão e torna os p-valores pequenos demais. O BH controla a taxa de falsas descobertas sob independência ou dependência positiva; os seis testes usam os mesmos dados, e isso não foi verificado.
O que a v2 faz	Simulação do C1 com efeito aleatório por local de votação; permutação do C4 em blocos (local e zona); erros agrupados no nível mais alto plausível; e Benjamini–Yekutieli (válido sob qualquer dependência) ao lado do BH.

8. Política confundida com fraude	séria
O que o v1 diz	2026 é comparado com 2022 sem nenhum controle além do 1º turno da mesma seção.
Por que é um problema	Candidatos, terceira via, comparecimento e economia mudaram entre os anos. Uma diferença entre 2026 e 2022 pode ser política, não fraude, e uma semelhança pode esconder duas mudanças em sentidos opostos. A comparação protege contra falso positivo, mas enfraquece a afirmação de normalidade.
O que a v2 faz	A classe de referência (crítica 1) dilui a dependência de uma eleição só. Os modelos ganham o perfil do eleitorado por seção (idade, escolaridade, sexo), que o TSE publica, como controle.

9. Inferência ecológica frágil	séria
O que o v1 diz	A transição usa uma identidade ad hoc (novos = max(0, ...), peso √n) e cita King e Manski sem usar os métodos deles. Cinco de dez intervalos são o próprio [0, 1].
Por que é um problema	Inferência ecológica é a tentativa de saber o comportamento de indivíduos a partir de totais de grupos. Sem hipóteses fortes, o dado só permite limites (bounds), e não um ponto. Apresentar pontos com intervalos de bootstrap, num modelo escolhido sem justificativa, passa uma precisão que a identificação não dá.
O que a v2 faz	A seção vira identificação parcial: os limites de Duncan–Davis por município, agregados, com a estimativa de King (1997) como ilustração, e a conclusão dita como faixa. Ela sai do corpo do artigo e vai para um apêndice, porque não testa nenhuma acusação.

10. Aproximações não verificadas no poder	séria
O que o v1 diz	Dentro do P1, os testes usam erros-padrão fixos, tirados da especificação sem fraude. Houve duas correções de código depois de rodar parte dos cenários.
Por que é um problema	Com fraude, a variância dos estimadores muda; usar o erro-padrão do caso sem fraude pode inflar ou reduzir o poder. As correções estão documentadas, o que é correto, mas um parecerista vai querer ver o antes e o depois lado a lado e uma checagem do código.
O que a v2 faz	Validar a versão leve contra a completa em alguns cenários com fraude (não só sem fraude); recalcular o erro-padrão dentro da réplica onde for barato; publicar o antes e o depois das correções; e testes automatizados do plantio (o total plantado bate com o pedido).

11. Falta a literatura	forma
O que o v1 diz	Não há seção de literatura.
Por que é um problema	Sem dialogar com o que já foi feito sobre a urna brasileira (relatórios de fiscalização de 2022, testes públicos de segurança do TSE, trabalhos acadêmicos de forense eleitoral), o leitor não sabe o que é novo.
O que a v2 faz	Seção de literatura curta: forense eleitoral (métodos e críticas), auditoria (risk-limiting audits) e o caso brasileiro.

12. Não tem a estrutura de um paper	forma
O que o v1 diz	Resumo de cerca de 250 palavras, sem seção de dados descritivos e sem discussão separada dos resultados.
Por que é um problema	Revistas pedem resumo de 150 a 200 palavras e uma estrutura previsível (introdução, literatura, dados, método, resultados, discussão). O leitor acadêmico navega por ela.
O que a v2 faz	Reestruturar nessa ordem, com estatística descritiva das seções (tamanho, comparecimento, fatia) em tabela própria.

13. Poucas figuras	forma
O que o v1 diz	Uma figura em sete páginas.
Por que é um problema	Testes sobre distribuições pedem que se mostre a distribuição. O histograma 2D de Klimek é o argumento visual do método, e a curva de especificações é como se mostra um multiverso.
O que a v2 faz	Figuras: histograma 2D (2026, referências), calibração dos modelos, posição de 2026 na distribuição de referência de cada teste, curva de especificações, curva de poder.

14. p-valores no piso de resolução	forma
O que o v1 diz	"p < 0,001" com 10.000 simulações e "p = 1,000" no texto.
Por que é um problema	Com 10.000 simulações, o menor p-valor possível é 1/10.001. Reportá-lo como prova forte é ler o piso da régua como se fosse a medida. E p = 1 em teste unilateral só diz que o efeito foi para o outro lado.
O que a v2 faz	Reportar "p < 1/10.001 (piso da simulação)" e, para efeito no sentido oposto, dizer isso em palavras com o tamanho do efeito.

15. Fuso horário não declarado	forma
O que o v1 diz	O C4 usa a hora de recebimento do boletim sem dizer em que fuso ela está.
Por que é um problema	Acre, Amazonas e o exterior têm fusos diferentes. Dentro do município isso não muda o resultado, mas o leitor não tem como saber sem ler o código.
O que a v2 faz	Declarar o fuso (o do registro do TSE) e a razão de ele não afetar a permutação.

16. Tom da conclusão	forma
O que o v1 diz	"Uma fraude capaz de mudar o resultado está descartada ao nível de 5%."
Por que é um problema	A frase é mais forte do que a análise sustenta, dadas as críticas 1 e 4. Um leitor cético lê o tom e desconfia do resto.
O que a v2 faz	"Nos formatos testados, e supondo que a referência seja limpa, uma fraude desse tamanho teria sido detectada com probabilidade de pelo menos 95%." O tamanho da afirmação acompanha o desenho.

Três ideias para levar

1. Um p-valor herda tudo do modelo nulo. Se o modelo erra sem fraude, o p-valor mede o erro. Antes de testar, mostre que o modelo descreve o caso sem efeito.

2. Não rejeitar não é aceitar. Para afirmar semelhança, fixe a margem antes e teste a equivalência. Para afirmar ausência, mostre o poder.

3. Onde não há amostra, não há intervalo de amostragem. Um censo tem outros limites (fonte, medição, definição), e são eles que precisam ser ditos.